

Các kiến thức nền tảng cần nắm chắc trong Machine Learning

A, Dữ liệu

I, Data types

1, Numerical:

- Integer: -2, -1, 0, 1, 2.
- Float: 0.4, 0.3, 1.5.

2, Categorical:

- Nominal: (Red, Green, Blue), (VietNam, US, China).
- Ordinal: (Happy, normal, sad), (XS, S, M, L, XL).
- Boolean: (True, False), (Yes, No).


II, Preprocessing Data

1, Làm sạch dữ liệu

Đây là bước đầu tiên để loại bỏ các thành phần gây nhiễu.

- **Xử lý giá trị thiếu (Missing Values):** Loại bỏ hàng/cột nếu dữ liệu thiếu quá nhiều. Điền giá trị dùng trung bình (**Mean**), trung vị (**Median**) cho dữ liệu số, hoặc giá trị xuất hiện nhiều nhất (**Mode**) cho dữ liệu phân loại.
- **Xử lý dữ liệu nhiễu (Outliers):** Sử dụng biểu đồ Boxplot hoặc chỉ số Z-score để phát hiện các điểm dữ liệu bất thường và quyết định cắt bỏ hoặc thay thế chúng (như mình đã thảo luận về tính "lì lợm" của MAE ở trên).
- **Xóa dữ liệu trùng lặp.**

LOG ANALYSIS



2, Biến đổi dữ liệu

Mô hình toán học chỉ làm việc được với con số và các đại lượng có cùng quy mô.

- **Mã hóa dữ liệu phân loại:**
 - **Label Encoding:** Chuyển chữ thành số (ví dụ: Thấp=0, Trung bình=1, Cao=2). Dùng khi dữ liệu có tính thứ tự.
 - **One-Hot Encoding:** Tạo ra các cột vector 0 và 1. Dùng khi các nhóm không có tính thứ tự (ví dụ: Màu sắc, Đất nước).
- **Chỉnh mức dữ liệu:** Đưa các đặc trưng về cùng một khoảng giá trị để thuật toán hội tụ nhanh hơn.
 - **Normalization (Min-Max Scaling):** Đưa về khoảng [0, 1].
 - **Standardization (Z-score Scaling):** Đưa về phân phối chuẩn có trung bình bằng 0 và độ lệch chuẩn bằng 1.

3, Lựa chọn và trích xuất đặc trưng.

- **Feature Selection:** Loại bỏ những cột không liên quan đến mục tiêu dự báo (ví dụ: ID sinh viên không giúp ích cho việc dự đoán điểm thi).
- **Feature Extraction:** Tạo ra đặc trưng mới từ những cái cũ (ví dụ: Từ "Ngày sinh" trích xuất thành "Tuổi").
- **Giảm chiều dữ liệu (Dimensionality Reduction):** Sử dụng các kỹ thuật như **PCA** (Principal Component Analysis) để nén dữ liệu mà vẫn giữ được nhiều thông tin nhất.

B, Model

I, Các dạng học

1, Supervised Learning

Classification:

- VD: Logistic Regression, Support Vector Machine, Decision Tree, KNN.

Regression:

- VD: Linear Regression.

2, Unsupervised Learning

Clustering:

- VD: K-Means Clustering.

3, Reinforcement Learning

II, Đánh giá mô hình

1, Đối với bài toán Classification

- **Accuracy:** Tỷ lệ dự đoán đúng trên tổng số mẫu. Dùng khi dữ liệu các lớp cân bằng nhau. Vô dụng khi dữ liệu lệch (ví dụ: 99% mẫu là Positive, 1% là Negative) khi này Accuracy không có ý nghĩa.
- **Precision:** Trong những mẫu mô hình báo là Positive, có bao nhiêu cái đúng thật (Tránh báo động nhầm).
- **Recall:** Trong những mẫu thực tế là Positive, mô hình tìm được bao nhiêu cái (Tránh bỏ sót).
- **F1-Score:** Trung bình điều hòa giữa Precision và Recall. Đây là điểm số công tâm nhất khi muốn cân bằng cả hai yếu tố trên.

2, Đối với bài toán **Regression**

- **MAE (Mean Absolute Error):** Trung bình lỗi tuyệt đối. Dễ hiểu vì đơn vị của nó giống hệt đơn vị của dữ liệu (ví dụ: lệch bao nhiêu triệu đồng).
- **RMSE (Root Mean Squared Error):** Căn bậc hai của MSE. Nó nhạy cảm với các sai số lớn hơn MAE. Nếu bạn thấy RMSE cao hơn hẳn MAE, chứng tỏ mô hình đang có những sai số cực nặng ở một vài mẫu.

III, Các hàm Loss phổ biến

1, Đối với bài toán **Regression**:

- **Mean Square Error (MSE):** Trung bình bình phương sai số. Đây là hàm phổ biến nhất. Nó phạt rất nặng những lỗi lớn vì sai số được bình phương lên.
- **Mean Absolute Error (MAE):** Trung bình trị tuyệt đối sai số.

2, Đối với bài toán **Classification**:

- **Binary Cross-Entropy (Log Loss):** Cho phân loại 2 lớp. Nó đo lường sự khác biệt giữa phân phối xác suất dự đoán và thực tế.
- **Categorical Cross-Entropy:** Dùng cho bài toán phân loại nhiều lớp (Multi-class). Thường đi kèm với hàm kích hoạt **Softmax** ở lớp cuối cùng.

IV, Regularization

V, Gradient Descent (Rất hay và quan trọng).